

```
curve
                                  float64
          free_kick_accuracy
                                  float64
          long_passing
                                  float64
          ball_control
                                  float64
                                  float64
          acceleration
          sprint_speed
                                  float64
          agility
                                  float64
          reactions
                                  float64
          balance
                                  float64
          shot_power
                                  float64
          jumping
                                  float64
 In [8]: # NO
          player2_position_list = player2_df.position.tolist()
 In [9]: player2_df = player2_df[[
              11
In [10]: player2_df.dtypes
          overall_rating
                                  float64
          potential
                                  float64
                                  float64
          crossing
          finishing
                                  float64
          heading_accuracy
                                  float64
          short_passing
                                  float64
                                  float64
          volleys
          dribbĺing
                                  float64
          curve
                                  float64
          free kick accuracy
                                  float64
          long_passing
                                  float64
          ball_control
                                  float64
          acceleration
                                  float64
          sprint_speed
                                  float64
          agility
                                  float64
          reactions
                                  float64
          balance
                                  float64
                                  float64
          shot_power
          jumping
                                  float64
In [11]: player2 df.sample(10)
                       overall_rating potential crossing finishing heading_accuracy short_passing volleys dribbling curve free_kick_accuracy ... vision penalt
           player name
            Rolando
Mandragora
                             60.93
                                      73.13
                                               47.87
                                                        44.33
                                                                                     69.33
                                                                                           41.67
                                                                                                     60.07 49.67
                                                                                                                            33.67
                                                                                                                                               31
                Daniel
                             59.71
                                      66.14
                                               59.57
                                                        32.14
                                                                        48.14
                                                                                     48.29
                                                                                           33,14
                                                                                                     52.29 57.57
                                                                                                                            39.14
                                                                                                                                      43.86
                                                                                                                                               46
               Pinillos
                                                                                                     44.00 47.00
               Stopira
                             60.25
                                      65.00
                                               56.00
                                                       28.00
                                                                        32.00
                                                                                     49.00
                                                                                          32.00
                                                                                                                            42.00 ...
                                                                                                                                      51.00
                                                                                                                                               45
                Kakha
                              78 50
                                      83 10
                                               67.30
                                                        32.80
                                                                        77.10
                                                                                     71.20
                                                                                            46 00
                                                                                                     51.70 44.00
                                                                                                                            48 30
                                                                                                                                      61.00
                                                                                                                                               64
           Sergi Darder
                             69.43
                                      75.61
                                                        39.13
                                                                        35.65
                                                                                     77.17
                                                                                            36.04
                                                                                                     63.83 61.87
                                                                                                                            54.26
                                                                                                                                      75.00
                                                                                                                                               38
                                               48.91
            Zeljko Brkic
                              75.00
                                      77.12
                                               18.50
                                                        19.00
                                                                        17.50
                                                                                     32.71
                                                                                            16.58
                                                                                                     20.17 17.88
                                                                                                                             18.42
                                                                                                                                      27.33
                                                                                                                                               31
               Stephen
                                                       67.14
                                                                        65.64
                                                                                                                            47.71 ...
                                                                                                                                               63
                             66.50
                                      70.93
                                                                                     59.79
                                                                                            61.14
                                                                                                     64.21 52.00
                                                                                                                                      64.93
                                               52.79
```

Aplicar Clustering sobre las features de los jugadores

Usar K-Means para el clustering.

dribbĺing

float64

Probar primero con 4 clusters, este numero se debe a cantidad de clases con respecto a la posicion de los jugadores:

- GK: Goalkeeper (Arquero)
- DEF: Defenser (Defensor)
- MID: Midfielder (Mediocampistas)
- FW: Forward (Delantero)

Luedo de hacer clustering, ver cuantos elementos tiene cada cluster.

```
purconcat([prayer_ur[ posteron ].reset_invex(), purvatarrame(nm_prev, corumns = [ cruster ])], axis = i).set_invex( prayer_
                  position cluster
        player_name
                          0
                     DEF
  Aaron Appindangoye
      Aaron Cresswell
                     DEF
                             3
        Aaron Doran MID 2
       Aaron Galindo
                     DEF
                             0
       Aaron Hughes DEF 0
                     MID
         Aaron Hunt
         Aaron Kuhl MID 0
                     MID
       Aaron Lennon
       Aaron Lennox GK 1
       Aaron Meijers
                    MID
                             3
```

```
In [14]: #side by side...
from IPython.display import display_html

def siamesas(*args):
    html_str = ''
    spaciador = '
    for df in args:
        html_str += df.to_html() + spaciador

    display_html(html_str.replace('table', 'table style = "display:inline"'), raw = True)
```

In [15]: #clases originales...
#... y predichas.
siamesas(pd.DataFrame(player_df.position.value_counts()), pd.DataFrame(pd.DataFrame(km_pred, columns = ['cluster']).cluster.value...

position			cluster	
DEF	3664	2	3506	
MID	3473	3	2877	
FW	1919	0	2673	
GK	869	1	869	

Evaluar resultados

Evaluar los resultados del clustering usando una medida como la Pureza.

Hint 1: Puede que en los clusters haya confusion entre las distintas posiciones dentro del campo de juego, esto no esta mal. Ya que hay que recordar que las posiciones estan simplicadas.

Hint 2: Un indicador de mala calidad es que haya clusters muy chiquitos y uno muy grande, lo cual indica que en el espacio no se distinguen bien grupos separados y hay que usar otro espacio.

```
In [16]: #purity..
         from sklearn import metrics
         contingency_matrix = metrics.cluster.contingency_matrix(player_df['position'].values, km_pred)
         print(contingency_matrix)
         print()
         print('Purity: {}'.format(contingency_matrix.max(axis = 1).sum() / contingency_matrix.sum()))
         [[2417 0
                      0 12471
           3 0 1
0 869
                  0 1881 35]
          253
                 0 1625 1595]]
         Purity: 0.6843324937027708
In [17]: #normalized mutual information or NMI...
         from sklearn.metrics.cluster import normalized_mutual_info_score
         print('NMI: {}'.format(normalized_mutual_info_score(player_df['position'].values, km_pred)))
         NMT: 0.5629166802850829
In [18]: #rand index score..
         from sklearn.metrics.cluster import adjusted_rand_score
         print('Rand index: {}'.format(adjusted_rand_score(player_df['position'].values, km_pred)))
         Rand index: 0.4033761167152728
```

Diferentes numero de clusters

Nota: Las posiciones asignadas a los jugadores son simplificadas, esto quiere decir que al hacer mas de 4 clusters podemos llegar descubrir posiciones mas especificas dentro del campo de juego (por ejemplo: Defensor central, Lateral derecho/izquierdo, Mediocampista defensivo/ofensivo, etc.)

Recordar: Calcular la Pureza para analizar si tener una mayor cantidad de clusters da meiores resultados.

```
In [19]: #

for bucle in range(4, 10):
    km_pred = KMeans(n_clusters = bucle, random_state = 42).fit_predict(player2_df)
    km_pred
    contingency_matrix = metrics.cluster.contingency_matrix(player_df['position'].values, km_pred)
    print('Purity para k={}: {}'.format(bucle, contingency_matrix.max(axis = 1).sum() / contingency_matrix.sum()))

Purity para k=4: 0.6843324937027708
Purity para k=5: 0.5802518891687657
Purity para k=6: 0.4738539042821159
Purity para k=6: 0.4738539042821159
Purity para k=7: 0.469823677581864
Purity para k=8: 0.39476070528967255
Purity para k=9: 0.374911838790932
```

Subconjunto de Features

Probar diferentes subconjunto de características del dataset para analizar si los resultados mejoran.

Por ejemplo, probar con el siguiente subconjunto de características:

- gk_diving
- gk_handling
- gk kicking
- gk_positioning
- standing_tackle
- sliding_tackle
- short_passing
- vision
- finishing
- volleys

Tambien probar con otros subconjuntos

Recordar: Calcular la Pureza

```
In [20]: #subset...
       player3 df.dtypes
Out[20]: gk_diving
                        float64
        gk handling
                        float64
        gk_kicking
                        float64
        gk_positioning
                        float64
        standing_tackle
                        float64
        sliding tackle
                        float64
                        float64
        short_passing
        vision
                        float64
        finishing
                        float64
        volleys
                        float64
       dtype: object
In [21]: #ejecutamos KMeans...
        km_pred = KMeans(n_clusters = k, random_state = 42).fit_predict(player3_df)
        contingency_matrix = metrics.cluster.contingency_matrix(player_df['position'].values, km_pred)
       print( Purity para k={}: {}'.format(k, contingency_matrix.max(axis = 1).sum() / contingency_matrix.sum()))
       Purity para k=4: 0.7182871536523929
```

Uso de Embedding

Aplicar el uso de embeddings, por ejemplo PCA, para comparar que sucede en ese espacio en comparacion con lo que sucede en el espacio original.

```
In [22]: #embedding sobre data total...
    from sklearn.preprocessing import StandardScaler

X = player2_df.values
y = player_df['position'].values

#estandarizamos X...
X = StandardScaler().fit_transform(X)

#PCA...
pca = PCA(n_components = 2)
PrincipalComponents = pca.fit_transform(X)

display(pd.DataFrame(PrincipalComponents, columns = ['PC_1', 'PC_2']))

#Kmeans sobre PCA...
km_pred = KMeans(n_clusters = 4, random_state = 42).fit_predict(X)

contingency_matrix = metrics.cluster.contingency_matrix(player_df['position'].values, km_pred)
```

```
print(contingency_matrix)
print()
print('Purity: {}'.format(contingency_matrix.max(axis = 1).sum() / contingency_matrix.sum()))
         PC 1
                 PC 2
0 0.852726 -2.371647
   1 -2.181250 -1.025895
  2 -2.072285 2.261744
   3 1.072629 -3.300898
 4 0.888563 -4.111527
  5 -5.112050 2.659132
6 0.202724 -1.337067
  7 -4.532535 4.263926
  8 13.546074 1.959586
  9 -3.000183 -0.831311
  10 -1.043719 -2.676473
```

mejora algunas décimas...

```
In [23]: #embedding sobre subset...

X = player3_df.values
y = player_df['position'].values

#estandarizamos X...
X = StandardScaler().fit_transform(X)

#PCA...
pca = PCA(n_components = 2)
PrincipalComponents = pca.fit_transform(X)

display(pd.DataFrame(PrincipalComponents, columns = ['PC_1', 'PC_2']))

#Kmeans sobre PCA...
km_pred = KMeans(n_clusters = 4, random_state = 42).fit_predict(X)

contingency_matrix = metrics.cluster.contingency_matrix(player_df['position'].values, km_pred)
print(contingency_matrix)
print()
print('Purity: {}'.format(contingency_matrix.max(axis = 1).sum() / contingency_matrix.sum()))
```

```
PC_1 PC_2

0 -0.961940 -1.366104

1 -0.724038 -1.588904

2 -0.537957 1.959659

3 -0.354235 -1.680743

4 -0.357011 -2.173166

5 -1.823971 2.536259

6 -0.337216 -1.190098

7 -1.323405 2.564355

8 6.246546 0.034693

9 -1.575023 -0.537682

10 -0.830914 -1.336465
```

mejora unos puntos...

Comunicación de Resultados

Se pide que toda esta información no quede plasmada solamente en un Jupyter Notebook, sino que se diagrame una comunicación en formato textual o interactivo (Google Docs, PDF o Markdown por ejemplo).

La comunicación debe estar apuntada a un público técnico pero sin conocimiento del tema particular, como por ejemplo, sus compañeros de clase.

In []: